



Facultad de Ingeniería en Sistemas, Informática y Ciencias de la Computación

Seminario de Investigación y Operaciones II

Dr. Jorge Samayoa

Modelo de regresión Resultados de carrera de F1

Ricardo Antonio Caballeros Gonzalez
Yoselin Yovana Mejía López
Kimberly Nathalia Hernandez León
Jorge Esteban Angelo Sanchez

Sección: A

Índice

Introducción.....	2
Objetivos.....	4
Objetivo general.....	4
Objetivos específicos.....	4
Modelos de Regresión.....	5
Variables a considerar.....	5
Feature engineering.....	6
P-Values.....	8
Métricas.....	9
Justificación.....	16
Conclusiones.....	17
Referencias.....	18

Introducción

Fórmula 1 es uno de los deportes más emocionantes y populares que existen hoy en día, en el que compiten los mejores corredores y los mejores fabricantes de carros en el Grand Prix para ver quien consigue el podio. Factores como su posición en la parrilla, la pista, la experiencia del piloto, las especificaciones del carro y el estilo de manejo de cada uno de los competidores va a determinar quienes van a poder subirse al podio.

Nosotros nos aventuramos a este proyecto para resolver la duda de ¿Qué factores determinan el resultado de la carrera? Y cómo es que cada uno de estos factores realmente afecta al resultado de la carrera.

Objetivos

Este proyecto fue realizado utilizando el dataset que se puede encontrar en Kaggle llamado **Formula 1 World Championship (1950 - 2024)**.

Al comenzar una carrera de Fórmula 1 hay múltiples partes que pueden llegar a afectar el resultado final de esta. Factores como la posición en la que se encuentra un corredor al inicio de la carrera, el motor, el piloto, la pista, el clima y muchos otros factores pueden determinar quienes van a entrar al podio. Nosotros disfrutamos el deporte y podemos tener una idea de cómo va a terminar una carrera por intuición pero queremos aplicar los conocimientos obtenidos para poder encontrar por medio de un modelo de regresión lo siguiente:

Objetivo general

Crear un modelo de regresión que sea capaz de determinar, no los aciertos, si no que los indicadores que pueden afectar en los resultados de la carrera.

Objetivos específicos

Luego de obtener los factores principales que contribuyen a estos resultados, queremos saber qué otras variables pueden brindarnos un mejor desempeño en el modelo de regresión.

Modelos de Regresión

Para este proyecto se realizaron dos modelos de regresión, uno simple de 3 variables que son las más importantes y en el segundo modelo se utilizaron 13 variables que encontramos que son relevantes para determinar el resultado de la carrera.

Variables a considerar

Ya que lo que queremos encontrar es la influencia de las variables en el resultado final de la carrera, el **primer modelo** lo utiliza las siguientes variables:

1. **grid:** Es la posición de salida del corredor.
2. **total_pit_time:** tiempo total en los pits.
3. **count_pit_stops:** cantidad de paradas a los pits.

Para el segundo modelo buscamos qué variables son relevantes para el modelo pero teniendo en consideración a los corredores y escuderías que hoy en día participan en las carreras. Tomamos las variables del modelo principal y lo que encontramos fue que el resultado va a variar si:

1. Está corriendo Red Bull
2. Está corriendo Ferrari
3. Está corriendo Mercedes
4. Está corriendo Sauber

5. Está corriendo Verstappen
6. Está corriendo Russel
7. Está corriendo Norris
8. Está corriendo Piastri
9. Está corriendo Magnussen
10. Está corriendo Sargeant

Feature engineering

Al procesar la data se realizaron varios pasos ya que es un dataset conformado por múltiples archivos de los que necesitamos obtener información. Fue un proceso de 12 partes:

1. **Carga de datos:** Las tablas que eran necesarias para el proyecto son `racas.csv`, `results.csv`, `drivers.csv`, `constructors.csv` y `pit_stops.csv` porque todos estos tienen información de las paradas a los pits.
2. **Limpieza de pit_stops:** Se transforma la columna `duration` a segundos, los valores nulos se eliminaron y se agruparon datos por `raceId` y `driverId`.
3. **Unificar tablas:** Se creó una tabla llamada `merged` que fue la combinación de todas las tablas mencionadas anteriormente para obtener la información relevante por piloto y carrera.
4. **Variables derivadas:** Se creó una variable para el tiempo promedio por parada (`avg_pit_time`), otra que indica si el piloto realizó alguna parada (`has_pit_stop`), para la siguiente se realizó una transformación logaritmica del tiempo total en los

pits para que los valores tan grandes no afecten el modelo (pit_time_log1p), una entre la interacción entre posicion inicial y número de paradas (grid_x_pits), otra para la interacción de posición inicial y tiempo total en pits (grid_x_total_pit_time) y dos para la normalización por la duración de la carrera (pit_stops_per_10laps y pit_time_per_lap).

5. **Limpieza de datos:** Se reemplazaron valores inválidos por NaN para mantener la consistencia y evitar errores en el modelo.
6. **Imputar datos:** Cuando un piloto no tuvo pits, colocamos cero porque refleja ausencia y no datos perdidos.
7. **Encoding:** Se aplicó One-Hot Encoding para los pilotos, equipos y circuitos. A partir de estas dummies se seleccionaron las variables más relevantes para el modelo complejo.
8. **Variables exógenas:** Se separaron las variables para ambos modelos.
9. **Variable endógena:** Declaramos position_order como nuestra variable endógena.
10. **Train/Val/Test split:** Split de 70/15/15 para evitar overfitting.

P-Values

1. grid $\rightarrow 3.23 \times 10^{-90}$
2. total_pit_time $\rightarrow 4.91 \times 10^{-21}$
3. count_pit_stops $\rightarrow 3.39 \times 10^{-47}$
4. Max Verstappen $\rightarrow 1.54 \times 10^{-2}$
5. Russell $\rightarrow 1.17 \times 10^{-6}$
6. Norris $\rightarrow 6.10 \times 10^{-5}$
7. Piastri $\rightarrow 2.15 \times 10^{-3}$
8. Magnussen $\rightarrow 3.99 \times 10^{-2}$
9. Sargeant $\rightarrow 1.92 \times 10^{-5}$
10. Red Bull $\rightarrow 6.98 \times 10^{-12}$
11. Ferrari $\rightarrow 1.98 \times 10^{-9}$
12. Mercedes $\rightarrow 2.62 \times 10^{-24}$
13. Sauber $\rightarrow 3.04 \times 10^{-2}$

Métricas

Se evaluaron cuatro modelos de regresión distintos, con el objetivo de determinar el impacto de la variable “count pit stops” en la predicción de los resultados de carrera. Se elaboraron dos versiones principales: una con 2 y 3 variables y otra con un modelo ampliado 12 y 13. En cada caso, se analizaron las métricas de desempeño en los conjuntos de entrenamiento, validación y prueba.


Modelos sin la variable “count pit stops”

Modelo con 2 variables

El modelo de dos variables presenta un R^2 ajustado de 0.361, lo que indica que solo el 36.1% de la variabilidad de la variable dependiente se explica a partir de las variables predictoras.

- En entrenamiento, el MAE (3.856) y el RMSE (4.890) evidencian un error medio relativamente alto.
- El R^2 en los tres conjuntos se mantiene alrededor de 0.33 – 0.36 tanto en entrenamiento, validación y pruebas, mostrando una capacidad explicativa limitada.
- Tanto la accuracy (0.83) como la precisión (0.60) reflejan un desempeño correcto, pero no sobresaliente.

En general, este modelo muestra una menor capacidad predictiva y explicativa, lo que sugiere que las variables incluidas no son suficientes para capturar la complejidad del fenómeno analizado.




Modelo con 12 variables

Por otro lado, el modelo con doce variables presenta un R^2 ajustado de 0.414, lo que mejora ligeramente el poder explicativo respecto al modelo anterior.

- Las métricas de error mejoran $MAE = 3.656$, $RMSE = 4.679$ y el R^2 alcanza hasta 0.401 con las pruebas.

- Las métricas de validación y prueba mantienen valores estables, con una exactitud promedio de 0.837 y precisión de 0.63.

Esto demuestra una mayor consistencia y mejor ajuste general, aunque la ausencia de la variable count pit stops sigue limitando la capacidad predictiva total del modelo.




Modelos con la variable “count pit stops”

Modelo con 3 variables

Este modelo obtiene un R^2 ajustado de 0.426, superior al de los modelos sin count pit stops.

- Los errores $MAE = 3.815$, $RMSE = 4.836$ son ligeramente menores, lo que indica predicciones más precisas.
- El R^2 en validación y prueba ronda $0.35 - 0.37$, mostrando buena estabilidad y ausencia de sobreajuste.
- Además, la precisión (0.61) y la accuracy (0.83) reflejan una mejor capacidad predictiva general.

Este resultado sugiere que la inclusión de count pit stops mejora significativamente la comprensión del comportamiento de los resultados, incluso en un modelo simple.



Modelo con 13 variables

El modelo que incluye la variable count pit stops presenta los mejores resultados globales:


- R^2 ajustado de 0.426 y R^2 de hasta 0.427 en entrenamiento, con valores similares en validación y prueba.
- Los errores se reducen aún más MAE (3.63), RMSE (4.63).

- Las métricas de precisión (0.65) y accuracy (0.84) son las más altas entre todos los modelos.

Estos indicadores reflejan un equilibrio ideal entre complejidad y rendimiento, demostrando que el modelo es capaz de capturar relaciones más finas entre las variables sin perder capacidad de generalización.

Ambas variables (`total_pit_time` y `count_pit_stops`) presentan una correlación alta, lo que indica que aportan información muy similar al modelo. Debido a esta redundancia, eliminar una de ellas no afecta significativamente el desempeño, ya que la variable restante sigue representando la misma relación con el objetivo.

Por tanto, los resultados en las métricas (R^2 , MAE, RMSE, Accuracy y Precisión) se mantienen prácticamente iguales al remover cualquiera de las dos. Esto demuestra que el modelo logra capturar de forma estable la influencia de las paradas en pits, sin depender estrictamente de una variable específica.



Justificación

La elección de los modelos de 3 y 13 variables se justifica porque presentan un mejor desempeño general en comparación con los modelos que excluyen la variable count pit stops. Estas versiones muestran menores errores (MAE y RMSE) y mayores valores de R^2 , reflejando una mayor capacidad explicativa y precisión en las predicciones. Aunque las variables total_pit_time y count_pit_stops están altamente correlacionadas, lo que significa que aportan información similar, la inclusión de al menos una de ellas resulta clave para representar adecuadamente la influencia de las paradas en pits. Por ello, los modelos con estas variables logran un equilibrio óptimo entre simplicidad, estabilidad y exactitud, sin evidencias de sobreajuste.

Conclusiones

Se determinó que el modelo con 13 variables presenta los mejores resultados generales; sin embargo, la mejora obtenida respecto al modelo de 3 variables no es lo suficientemente significativa como para justificar el incremento en la complejidad.

El modelo simple, con solo tres variables, logra capturar de manera eficiente la relación entre los factores de carrera y la posición final, manteniendo un equilibrio adecuado entre precisión e interpretabilidad.

Asimismo, se observó que las variables **total_pit_time** y **count_pit_stops** describen el mismo fenómeno, presentando una alta correlación entre sí. La eliminación de cualquiera de estas variables no modifica de forma significativa los resultados del modelo, ya que las métricas se mantienen prácticamente iguales. Esto demuestra que el modelo es capaz de representar correctamente la influencia de las paradas en boxes sin necesidad de incluir ambas variables, evitando redundancia y conservando su desempeño predictivo.

Referencias

Google colab. (n.d.). Google.com. Retrieved November 10, 2025, from <https://colab.research.google.com/drive/1O5Yn-0-wK-jV2ED16XFBXRGkeqGJRgqk?usp=sharing>

Vopani. (2025). *Formula 1 World Championship (1950 - 2024)* [Data set].